

2.5 证明 MSE 方法在选两类样本的 b 值分别为 N/N_1 和 N/N_2 时得到的解等价于 Fisher 线性判别的解且 $w_0 = -\hat{m}$, 其中 N, N_1, N_2 分别为样本总数和两类样本的数目。

证明：这里延续课件的表达，有 MSE 的解如下形式

$$a^* = (Y^T Y)^{-1} Y^T b$$

$$\text{样本分为两类分别为 } X_1, X_2, \text{ 于是 } Y = \begin{bmatrix} I_1 & X_1 \\ -I_2 & X_2 \end{bmatrix}, a = \begin{bmatrix} w_0 \\ w \end{bmatrix}$$

$$\text{根据题目要求有 } b = \begin{bmatrix} \frac{N}{N_1} & I_1 \\ \frac{N}{N_2} & I_2 \end{bmatrix}$$

$$\text{由 } Y^T Y a = Y^T b \text{ 得 } \begin{bmatrix} I_1^T & -I_2^T \\ X_1^T & -X_2^T \end{bmatrix} \begin{bmatrix} I_1 & X_1 \\ -I_2 & -X_2 \end{bmatrix} \begin{bmatrix} w_0 \\ w \end{bmatrix} = \begin{bmatrix} I_1^T & -I_2^T \\ X_1^T & -X_2^T \end{bmatrix} \begin{bmatrix} \frac{N}{N_1} & I_1 \\ \frac{N}{N_2} & I_2 \end{bmatrix}$$

$$m_1 = \frac{1}{N_1} \sum_1 x_i, m_2 = \frac{1}{N_2} \sum_2 x_i$$

$$\begin{aligned} S_w &= \sum_1 (x_i - m_1)(x_i - m_1)^T + \sum_2 (x_i - m_2)(x_i - m_2)^T \\ &= X_1^T X_1 - N_1 m_1 m_1^T + X_2^T X_2 - N_2 m_2 m_2^T \end{aligned}$$

进而有

$$\begin{bmatrix} N & (N_1 m_1 + N_2 m_2)^T \\ N_1 m_1 + N_2 m_2 & S_w + N_1 m_1 m_1^T + N_2 m_2 m_2^T \end{bmatrix} \begin{bmatrix} w_0 \\ w \end{bmatrix} = \begin{bmatrix} 0 \\ N(m_1 - m_2) \end{bmatrix}$$

于是

$$\begin{aligned} N w_0 + N_1 m_1^T w + N_2 m_2^T w &= 0 \\ N w_0 + N m^T w &= 0 \end{aligned}$$

得

$$w_0 = -m^T w = -\hat{m}$$

又

$$\begin{aligned} (N_1 m_1 + N_2 m_2) w_0 + (S_w + N_1 m_1 m_1^T + N_2 m_2 m_2^T) w &= N(m_1 - m_2) \\ -(N_1 m_1 + N_2 m_2) m^T w + (S_w + N_1 m_1 m_1^T + N_2 m_2 m_2^T) w &= N(m_1 - m_2) \\ -\frac{(N_1 m_1 + N_2 m_2)(N_1 m_1^T + N_2 m_2^T)}{N} w + (N_1 m_1 m_1^T + N_2 m_2 m_2^T) w + S_w w &= N(m_1 - m_2) \\ \frac{N_1 N_2}{N} (m_1 - m_2)(m_1 - m_2)^T w + S_w w &= N(m_1 - m_2) \end{aligned}$$

$$\frac{N_1 N_2}{N} (m_1 - m_2)(m_1 - m_2)^T w \text{ 的方向与 } (m_1 - m_2) \text{ 相同, 于是 } S_w w \text{ 的方向也必与}$$

$(m_1 - m_2)$ 相同, 因此 $S_w w = k(m_1 - m_2)$, 得 $w = k S_w^{-1} (m_1 - m_2)$, 与 Fisher 线性判别的解等价。



最优判别的渐近逼近

$B=I_n$ 时, MSE的解等同于以最小均方

误差逼近Bayes 判别函数:

$$g_0(\mathbf{x}) = P(\omega_1 | \mathbf{x}) - P(\omega_2 | \mathbf{x})$$

即MSE的分类面

接近贝叶斯分类面

证明: 按照概率定律

$$p(\mathbf{x}) = p(\mathbf{x} | \omega_1)P(\omega_1) + p(\mathbf{x} | \omega_2)P(\omega_2)$$

独立同分布抽取样本, 得到

$$g(\mathbf{x}) = \mathbf{a}^t \mathbf{y}, \quad \mathbf{y} = \mathbf{y}(\mathbf{x})$$

定义均方逼近误差为

$$\varepsilon^2 = \int [\mathbf{a}^t \mathbf{y} - g_0(\mathbf{x})]^2 p(\mathbf{x}) d\mathbf{x}$$



最优判别的渐近逼近

当 $\mathbf{b} = \mathbf{1}_n$ 时, 最小均方误差准则函数为:

$$J_s(\mathbf{a}) = \sum_{\mathbf{y} \in Y_1} (\mathbf{a}^t \mathbf{y} - 1)^2 + \sum_{\mathbf{y} \in Y_2} (\mathbf{a}^t \mathbf{y} + 1)^2$$

$$= n \left[\frac{n_1}{n} \frac{1}{n_1} \sum_{\mathbf{y} \in Y_1} (\mathbf{a}^t \mathbf{y} - 1)^2 + \frac{n_2}{n} \frac{1}{n_2} \sum_{\mathbf{y} \in Y_2} (\mathbf{a}^t \mathbf{y} + 1)^2 \right]$$

利用大数定理, n 趋向无穷大时

$$J(\mathbf{a}) = \frac{1}{n} J_s(\mathbf{a}) = P(\omega_1) E_1 \left[(\mathbf{a}^t \mathbf{y} - 1)^2 \right] + P(\omega_2) E_2 \left[(\mathbf{a}^t \mathbf{y} + 1)^2 \right]$$

$$\text{其中, } E_1 \left[(\mathbf{a}^t \mathbf{y} - 1)^2 \right] = \int (\mathbf{a}^t \mathbf{y} - 1)^2 p(\mathbf{x} | \omega_1) d\mathbf{x}$$

$$E_2 \left[(\mathbf{a}^t \mathbf{y} + 1)^2 \right] = \int (\mathbf{a}^t \mathbf{y} + 1)^2 p(\mathbf{x} | \omega_2) d\mathbf{x}$$

最优判别的渐近逼近

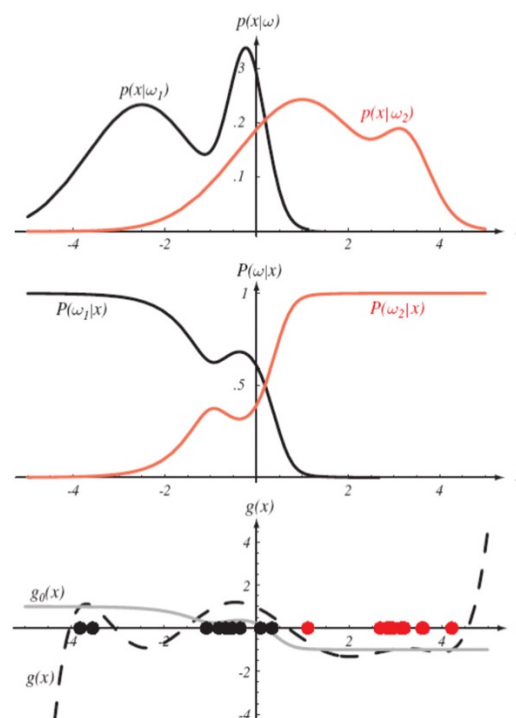
$$g_0(\mathbf{x}) = \frac{p(\mathbf{x}, \omega_1) - p(\mathbf{x}, \omega_2)}{p(\mathbf{x})}$$

$$\begin{aligned} \bar{J}(\mathbf{a}) &= \int (\mathbf{a}^t \mathbf{y} - 1)^2 p(\mathbf{x}, \omega_1) d\mathbf{x} + \int (\mathbf{a}^t \mathbf{y} + 1)^2 p(\mathbf{x}, \omega_2) d\mathbf{x} \\ &= \int (\mathbf{a}^t \mathbf{y})^2 p(\mathbf{x}) d\mathbf{x} - 2 \int \mathbf{a}^t \mathbf{y} g_0(\mathbf{x}) p(\mathbf{x}) d\mathbf{x} + 1 \\ &= \int [\mathbf{a}^t \mathbf{y} - g_0(\mathbf{x})]^2 p(\mathbf{x}) d\mathbf{x} + [1 - \int g_0^2(\mathbf{x}) p(\mathbf{x}) d\mathbf{x}] \\ &= \varepsilon^2 + \text{独立于 } \mathbf{a} \text{ 的成分} \end{aligned}$$

于是，MSE的解等同于以最小均方误差逼近Bayes 判别函数：

$$g_0(\mathbf{x}) = P(\omega_1 | \mathbf{x}) - P(\omega_2 | \mathbf{x})$$

MSE 解和 Bayes 判别函数



22:17 11月29日周二 math.pku.edu.cn 100%

3/16

例解

- $\omega_1: (1,2)^t$ and $(2,0)^t$
- $\omega_2: (3,1)^t$ and $(2,3)^t$

Sample Matrix ($d = 1+2, n = 4$)

$$Y = \begin{bmatrix} 1 & 1 & 2 \\ 1 & 2 & 0 \\ -1 & -3 & -1 \\ -1 & -2 & -3 \end{bmatrix}$$

Pseudo-inverse

$$Y^* = (Y^T Y)^{-1} Y^T = \begin{bmatrix} 5/4 & 13/12 & 3/4 & 7/12 \\ -1/2 & -1/6 & -1/2 & -1/6 \\ 0 & -1/3 & 0 & -1/3 \end{bmatrix}$$

Assuming $b = \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}$

our solution is $a = Y^* b = \begin{bmatrix} 11/3 \\ -4/3 \\ -2/3 \end{bmatrix}$

$a^T \begin{pmatrix} 1 \\ x_1 \\ x_2 \end{pmatrix} = 0$

22:17 11月29日周二 math.pku.edu.cn 100%

4/16

MSE解与 Bayes 判别函数的关系

当 $N \rightarrow \infty$, $\mathbf{b} = \mathbf{1}_n$ 时, MSE的解以最小均方误差逼近 Bayes 判别函数: $g_0(\mathbf{x}) = p(\omega_1 | \mathbf{x}) - p(\omega_2 | \mathbf{x})$;

- 均方误差
$$e^2 = \int [\mathbf{a}^T \mathbf{y} - g_0(\mathbf{x})]^2 p(\mathbf{x}) d\mathbf{x};$$
- 即有 $\mathbf{a}^* \equiv Y^+ \mathbf{b} = \arg \min e^2.$

$$J_s(\mathbf{a}) = \sum_{\mathbf{x}_i \in \omega_1} (\mathbf{a}^T \mathbf{y}_i - 1)^2 + \sum_{\mathbf{x}_i \in \omega_2} (\mathbf{a}^T \mathbf{y}_i + 1)^2$$

$$= N \left(\frac{N_1}{N} \frac{1}{N_1} \sum_{\mathbf{x}_i \in \omega_1} (\mathbf{a}^T \mathbf{y}_i - 1)^2 + \frac{N_2}{N} \frac{1}{N_2} \sum_{\mathbf{x}_i \in \omega_2} (\mathbf{a}^T \mathbf{y}_i + 1)^2 \right);$$

22:17 11月29日周二 math.pku.edu.cn 100%

5/16

MSE解与 Bayes 判别函数的关系

$$\frac{J_s(\mathbf{a})}{N}$$

$$\doteq P(\omega_1) \int (\mathbf{a}^T \mathbf{y} - 1)^2 p(\mathbf{x} | \omega_1) d\mathbf{x} + P(\omega_2) \int (\mathbf{a}^T \mathbf{y} + 1)^2 p(\mathbf{x} | \omega_2) d\mathbf{x}$$

$$= \int (\mathbf{a}^T \mathbf{y} - 1)^2 p(\mathbf{x}, \omega_1) d\mathbf{x} + \int (\mathbf{a}^T \mathbf{y} + 1)^2 p(\mathbf{x}, \omega_2) d\mathbf{x}$$

$$= \int \left\{ (\mathbf{a}^T \mathbf{y})^2 [p(\mathbf{x}, \omega_1) + p(\mathbf{x}, \omega_2)] - 2\mathbf{a}^T \mathbf{y} \frac{p(\mathbf{x}, \omega_1) - p(\mathbf{x}, \omega_2)}{p(\mathbf{x})} \times p(\mathbf{x}) + [p(\mathbf{x}, \omega_1) + p(\mathbf{x}, \omega_2)] \right\} d\mathbf{x}$$

$$= \int (\mathbf{a}^T \mathbf{y})^2 p(\mathbf{x}) d\mathbf{x} - 2 \int (\mathbf{a}^T \mathbf{y}) g_0(\mathbf{x}) p(\mathbf{x}) d\mathbf{x} + 1$$

$$= \int [\mathbf{a}^T \mathbf{y} - g_0(\mathbf{x})]^2 p(\mathbf{x}) d\mathbf{x} + \left[1 - \int g_0^2(\mathbf{x}) p(\mathbf{x}) d\mathbf{x} \right]$$

$$= e^2 + \left[1 - \int g_0^2(\mathbf{x}) p(\mathbf{x}) d\mathbf{x} \right];$$

求解MSE解

□ 计算 $\mathbf{a}^* = Y^\dagger \mathbf{b}$, 其中 $Y^\dagger = (Y^T Y)^{-1} Y^T$;

□ 梯度下降法

$$\nabla J_s(\mathbf{a}) = \sum_{i=1}^N 2(\mathbf{a}^T \mathbf{y}_i - b_i) \mathbf{y}_i = 2Y^T (Y\mathbf{a} - \mathbf{b})$$

$$\begin{cases} \mathbf{a}(1), \text{ 任意初始化} \\ \mathbf{a}(k+1) = \mathbf{a}(k) - \eta(k) Y^T (Y\mathbf{a} - \mathbf{b}) \end{cases}$$

until $\nabla J_s(\mathbf{a}) \leq \theta$ 或者 $\|\mathbf{a}(k+1) - \mathbf{a}(k)\| \leq \theta$;

可选 $\eta(k) = \eta(1)/k$ ($\eta(1) > 0$).

求解MSE解

□ 单样本修正法 (Widrow-Hoff 算法, LMS)

$$\begin{cases} \mathbf{a}(1), \text{ 任意初始化} \\ \mathbf{a}(k+1) = \mathbf{a}(k) + \eta(k)(b_k - \mathbf{a}(k)^T \mathbf{y}^k) \mathbf{y}^k \end{cases}$$

其中 \mathbf{y}^k 是使得 $\mathbf{a}(k)^T \mathbf{y}^k \neq b_k$ 的样本。

Algorithm 10 (LMS)

```

1 begin initialize  $\mathbf{a}, \mathbf{b}$ , criterion  $\theta, \eta(\cdot), k = 0$ 
2   do  $k \leftarrow k + 1$ 
3      $\mathbf{a} \leftarrow \mathbf{a} + \eta(k)(b_k - \mathbf{a}^T \mathbf{y}^k) \mathbf{y}^k$ 
4   until  $\eta(k)(b_k - \mathbf{a}^T \mathbf{y}^k) \mathbf{y}^k < \theta$ 
5   return  $\mathbf{a}$ 
6 end
```