

## 第五章 线性判别函数

4、考虑判别中用的超平面。

(a) 证明在从超平面  $g(\mathbf{x}) = \mathbf{w}'\mathbf{x} + w_0 = 0$  到点  $\mathbf{x}_a$  的距离为  $|g(\mathbf{x}_a)|/\|\mathbf{w}\|$ ，且对应的点

为约束条件  $g(\mathbf{x}) = 0$  下的满足使  $\|\mathbf{x} - \mathbf{x}_a\|^2$  最小的  $\mathbf{x}$ 。

(b) 证明  $\mathbf{x}_a$  到超平面的投影为：

$$\mathbf{x}_p = \mathbf{x}_a - \frac{g(\mathbf{x}_a)}{\|\mathbf{w}\|^2} \mathbf{w}$$

证明：

(a) 令  $\mathbf{x}_p$  为点  $\mathbf{x}_a$  在超平面  $g(\mathbf{x}) = 0$  上的投影点，即矢量  $\mathbf{x}_a - \mathbf{x}_p$  “垂直于”超平面，令模

长为  $r$ ，即：  $\|\mathbf{x}_a - \mathbf{x}_p\| = r$ 。同时权矢量  $\mathbf{w}$  为超平面  $g(\mathbf{x}) = 0$  的法矢量，也“垂直于”

超平面，因此  $\mathbf{x}_a - \mathbf{x}_p$  与  $\mathbf{w}$  方向相同（假设  $\mathbf{x}_a$  处在超平面的正侧），因此有：

$$\mathbf{x}_a - \mathbf{x}_p = r \frac{\mathbf{w}}{\|\mathbf{w}\|}, \quad \left( \text{其中 } \frac{\mathbf{w}}{\|\mathbf{w}\|} \text{ 为单位矢量} \right)$$

$$\mathbf{x}_a = \mathbf{x}_p + r \frac{\mathbf{w}}{\|\mathbf{w}\|}$$

等式两边左乘  $\mathbf{w}'$ ：

$$\mathbf{w}'\mathbf{x}_a = \mathbf{w}'\mathbf{x}_p + r \frac{\mathbf{w}'\mathbf{w}}{\|\mathbf{w}\|} = \mathbf{w}'\mathbf{x}_p + r \|\mathbf{w}\|$$

而：

$$\begin{aligned} g(\mathbf{x}_a) &= \mathbf{w}'\mathbf{x}_a + w_0 \\ &= \mathbf{w}'\mathbf{x}_p + r \|\mathbf{w}\| + w_0 \\ &= g(\mathbf{x}_p) + r \|\mathbf{w}\| = r \|\mathbf{w}\| \quad (\mathbf{x}_p \text{ 为超平面上点, } g(\mathbf{x}_p) = 0) \end{aligned}$$

因此：

$$r = \frac{g(\mathbf{x}_a)}{\|\mathbf{w}\|}$$

当  $\mathbf{x}_a$  处于超平面的负侧时,  $g(\mathbf{x}_a) < 0$ , 同理可得  $r = -\frac{g(\mathbf{x}_a)}{\|\mathbf{w}\|}$ , 因此:

$$r = \frac{|g(\mathbf{x}_a)|}{\|\mathbf{w}\|}$$

令  $\mathbf{x}_q$  为超平面上的点,  $\mathbf{x}_p$  为点  $\mathbf{x}_a$  在超平面上的投影点, 则有:

$$\mathbf{x} - \mathbf{x}_q = (\mathbf{x} - \mathbf{x}_p) + (\mathbf{x}_p - \mathbf{x}_q)$$

两边分别左乘  $(\mathbf{x} - \mathbf{x}_q)^t$  和  $[(\mathbf{x} - \mathbf{x}_p) + (\mathbf{x}_p - \mathbf{x}_q)]^t$ , 则有等式:

$$\begin{aligned} (\mathbf{x} - \mathbf{x}_q)^t (\mathbf{x} - \mathbf{x}_q) &= [(\mathbf{x} - \mathbf{x}_p) + (\mathbf{x}_p - \mathbf{x}_q)]^t [(\mathbf{x} - \mathbf{x}_p) + (\mathbf{x}_p - \mathbf{x}_q)] \\ &= (\mathbf{x} - \mathbf{x}_p)^t (\mathbf{x} - \mathbf{x}_p) + (\mathbf{x} - \mathbf{x}_p)^t (\mathbf{x}_p - \mathbf{x}_q) \\ &\quad + (\mathbf{x}_p - \mathbf{x}_q)^t (\mathbf{x} - \mathbf{x}_p) + (\mathbf{x}_p - \mathbf{x}_q)^t (\mathbf{x}_p - \mathbf{x}_q) \end{aligned}$$

其中:

$$\begin{aligned} (\mathbf{x} - \mathbf{x}_q)^t (\mathbf{x} - \mathbf{x}_q) &= \|\mathbf{x} - \mathbf{x}_q\|^2 \\ (\mathbf{x} - \mathbf{x}_p)^t (\mathbf{x} - \mathbf{x}_p) &= \|\mathbf{x} - \mathbf{x}_p\|^2 \\ (\mathbf{x}_p - \mathbf{x}_q)^t (\mathbf{x}_p - \mathbf{x}_q) &= \|\mathbf{x}_p - \mathbf{x}_q\|^2 \end{aligned}$$

由于矢量  $\mathbf{x} - \mathbf{x}_p$  与超平面正交, 而  $\mathbf{x}_p - \mathbf{x}_q$  处在超平面内, 因此:

$$(\mathbf{x} - \mathbf{x}_p)^t (\mathbf{x}_p - \mathbf{x}_q) = (\mathbf{x}_p - \mathbf{x}_q)^t (\mathbf{x} - \mathbf{x}_p) = 0$$

所以:

$$\|\mathbf{x} - \mathbf{x}_q\|^2 = \|\mathbf{x} - \mathbf{x}_p\|^2 + \|\mathbf{x}_p - \mathbf{x}_q\|^2 \geq \|\mathbf{x} - \mathbf{x}_p\|^2$$

只有当  $\mathbf{x}_p = \mathbf{x}_q$  时取得等号。因此  $\mathbf{x}_p$  是使约束条件  $g(\mathbf{x}) = 0$  下的满足使  $\|\mathbf{x} - \mathbf{x}_a\|^2$  最小的  $\mathbf{x}$ 。

(b) 当  $\mathbf{x}_a$  处于超平面的正侧时:

$$\mathbf{x}_a - \mathbf{x}_p = r \frac{\mathbf{w}}{\|\mathbf{w}\|} = \frac{g(\mathbf{x}_a)}{\|\mathbf{w}\|} \frac{\mathbf{w}}{\|\mathbf{w}\|} = \frac{g(\mathbf{x}_a)}{\|\mathbf{w}\|^2} \mathbf{w}$$

当  $\mathbf{x}_a$  处于超平面的负侧时:

$$\mathbf{x}_a - \mathbf{x}_p = -r \frac{\mathbf{w}}{\|\mathbf{w}\|} = -\frac{-g(\mathbf{x}_a)}{\|\mathbf{w}\|} \frac{\mathbf{w}}{\|\mathbf{w}\|} = \frac{g(\mathbf{x}_a)}{\|\mathbf{w}\|^2} \mathbf{w}$$

因此:

$$\mathbf{x}_p = \mathbf{x}_a - \frac{g(\mathbf{x}_a)}{\|\mathbf{w}\|^2} \mathbf{w}$$

14、考虑平方误差准则函数:

$$J_s(\mathbf{a}) = \sum_{i=1}^n (\mathbf{a}' \mathbf{y}_i - b_i)^2$$

令  $b_i = b$ , 取如下 6 个训练点:

$$\mathbf{w}_1: (1, 5)^t, (2, 9)^t, (-5, -3)^t$$

$$\mathbf{w}_2: (2, -3)^t, (-1, -4)^t, (0, 2)^t$$

- (a) 计算它的Hessian矩阵;  
(b) 假定二次准则函数, 计算最优学习率  $\mathbf{h}$ 。

解:

(a)

$$\nabla J = \frac{dJ_s(\mathbf{a})}{d\mathbf{a}} = \sum_{i=1}^n 2(\mathbf{a}' \mathbf{y}_i - b_i) \mathbf{y}_i$$

$$\mathbf{H} = 2 \sum_{i=1}^n \mathbf{y}_i \mathbf{y}_i'$$

将样本变为增广向量:

$$\mathbf{y}_1 = \begin{pmatrix} 1 \\ 1 \\ 5 \end{pmatrix}, \mathbf{y}_2 = \begin{pmatrix} 1 \\ 2 \\ 9 \end{pmatrix}, \mathbf{y}_3 = \begin{pmatrix} 1 \\ -5 \\ -3 \end{pmatrix}$$

$$\mathbf{y}_4 = \begin{pmatrix} -1 \\ -2 \\ 3 \end{pmatrix}, \mathbf{y}_5 = \begin{pmatrix} -1 \\ 1 \\ 4 \end{pmatrix}, \mathbf{y}_6 = \begin{pmatrix} -1 \\ 0 \\ -2 \end{pmatrix}$$

Hessian 矩阵为:

$$\mathbf{H} = \begin{pmatrix} 12 & -2 & 12 \\ -2 & 70 & 72 \\ 12 & 72 & 288 \end{pmatrix}$$

- (b) 准则函数为二次函数, 因此  $J_s$  在  $\mathbf{a}(k)$  附近的 Taylor 展开式为:

$$J_s(\mathbf{a}(k+1)) = J_s(\mathbf{a}(k)) + \nabla J_s'(\mathbf{a}(k))(\mathbf{a} - \mathbf{a}(k)) + \frac{1}{2}(\mathbf{a} - \mathbf{a}(k))' \mathbf{H}(\mathbf{a} - \mathbf{a}(k))$$

$$\text{而: } \mathbf{a}(k+1) = \mathbf{a}(k) - h(k) \nabla J(\mathbf{a}(k))$$

因此:

$$J_s(\mathbf{a}(k+1)) = J(\mathbf{a}(k)) - h(k) \|\nabla J(\mathbf{a}(k))\|^2 + \frac{1}{2} h^2(k) \nabla J'(\mathbf{a}(k)) \mathbf{H} \nabla J(\mathbf{a}(k))$$

寻找使得  $J_s(\mathbf{a}(k+1))$  最小的  $h(k)$ , 上式对  $h(k)$  求导数:

$$\frac{dJ_s(\mathbf{a}(k+1))}{dh(k)} = -\|\nabla J(\mathbf{a}(k))\|^2 + h(k) \nabla J'(\mathbf{a}(k)) \mathbf{H} \nabla J(\mathbf{a}(k)) = 0$$

因此最优学习率:

$$h(k) = \frac{\|\nabla J(\mathbf{a}(k))\|^2}{\nabla J'(\mathbf{a}(k)) \mathbf{H} \nabla J(\mathbf{a}(k))}$$

15、在感知器算法的收敛证明中(定理 5.1)取尺度因子  $a = b^2/g$ 。

(a) 用 5.5 节的符号, 证明如果  $a > b^2/(2g)$ , 那么需要校正的次数的最大值为:

$$k_0 = \frac{\|\mathbf{a}_1 - a\hat{\mathbf{a}}\|^2}{2ag - b^2}$$

(b) 当  $\mathbf{a}_1 = \mathbf{0}$  时,  $a$  为何值时使得  $k_0$  最小?

证明:

(a) 在定理 5.1 证明中, 有如下不等式成立:

$$\|\mathbf{a}(k+1) - a\hat{\mathbf{a}}\|^2 \leq \|\mathbf{a}(k) - a\hat{\mathbf{a}}\|^2 - 2ag + b^2$$

如果取  $a > b^2/(2g)$ , 则有  $2ag > b^2$ ,  $2ag - b^2 > 0$ 。即每次迭代之后  $\mathbf{a}(k+1)$  到  $a\hat{\mathbf{a}}$

距离的平方减小了  $2ag - b^2$ , 经  $k$  次迭代之后:

$$\|\mathbf{a}(k+1) - a\hat{\mathbf{a}}\|^2 \leq \|\mathbf{a}(1) - a\hat{\mathbf{a}}\|^2 - k(2ag - b^2)$$

因  $\|\mathbf{a}(1) - a\hat{\mathbf{a}}\|^2 - k(2ag - b^2) \geq 0$ , 所以经过不超过  $k_0$  此的迭代之后, 终止:

$$k_0 = \frac{\|\mathbf{a}(1) - a\hat{\mathbf{a}}\|^2}{2ag - b^2}$$

(b) 当  $\mathbf{a}(1) = \mathbf{0}$  时:

$$k_0 = \frac{\| -a\hat{\mathbf{a}} \|^2}{2ag - b^2} = \frac{\|\hat{\mathbf{a}}\|^2}{2g/a - b^2/a^2}$$

求  $k_0$  的最小值，即求  $2g/a - b^2/a^2$  的最大值，令  $q = \frac{1}{a}$ ，构造目标函数：

$$J(q) = 2gq - b^2q^2$$

$$\frac{dJ(q)}{dq} = 2g - 2b^2q = 0$$

因此： $q = \frac{g}{b^2}$ ，即当  $a = \frac{b^2}{g}$  时， $k_0$  取得极值，可以验证此极值为  $k_0$  的最小值。

## 第 10 章 无监督学习和聚类

14、 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$  为  $n$  个  $d$  维样本， $\Sigma$  是任意的大小为  $d \times d$  的非奇异矩阵，证明使得：

$$\sum_{k=1}^n (\mathbf{x}_k - \mathbf{x})' \Sigma^{-1} (\mathbf{x}_k - \mathbf{x})$$

最小的  $\mathbf{x}$  就是样本的均值  $\bar{\mathbf{x}} = 1/n \sum_{k=1}^n \mathbf{x}_k$ 。

证明：令：

$$J(\mathbf{x}) = \sum_{k=1}^n (\mathbf{x}_k - \mathbf{x})' \Sigma^{-1} (\mathbf{x}_k - \mathbf{x})$$

则：

$$\frac{dJ(\mathbf{x})}{d\mathbf{x}} = \sum_{k=1}^n \left( \Sigma^{-1} + (\Sigma^{-1})' \right) (\mathbf{x} - \mathbf{x}_k) = \mathbf{0}$$

因此：

$$n \left( \Sigma^{-1} + (\Sigma^{-1})' \right) \mathbf{x} = \left( \Sigma^{-1} + (\Sigma^{-1})' \right) \sum_{k=1}^n \mathbf{x}_k$$

假设  $\left( \Sigma^{-1} + (\Sigma^{-1})' \right)$  非奇异，等式两边左乘  $\left( \Sigma^{-1} + (\Sigma^{-1})' \right)^{-1}$ ，则有：

$$\mathbf{x} = 1/n \sum_{k=1}^n \mathbf{x}_k。$$