

贝叶斯学习 (为了反映样本数据) 是一个过程

样本集重新定义 $X^N = \{x_1, x_2, \dots, x_N\}$ 不喜欢这种不一致定义

贝叶斯估计 $\theta^* = \int_{\Theta} \theta p(\theta | X^N) d\theta$

当 $N > 1$ 时, $p(X^N | \theta) = p(x_N | \theta) \cdot p(X^{N-1} | \theta)$ I.I.D 假设

$p(\theta | X^N) = \frac{p(X^N | \theta) p(\theta)}{\int_{\Theta} p(X^N | \theta) p(\theta) d\theta}$ 分子分母相同形式

为了用 X^N 提出

$p(X^N | \theta) \cdot p(\theta) = p(x_N | \theta) \cdot p(X^{N-1} | \theta) \cdot p(\theta)$

$= p(x_N | \theta) \cdot \frac{p(X^{N-1}, \theta)}{p(\theta)} \cdot p(\theta)$

$= p(x_N | \theta) \cdot p(X^{N-1}, \theta)$

$= p(x_N | \theta) \cdot p(\theta | X^{N-1}) \cdot p(X^{N-1})$

X^{N-1} 对 $d\theta$ 不是变量 故分母积分下 X^{N-1} 可提出,

与分子约分。

$$\int_{\theta} p(X^N, \theta) d\theta = p(X^N)$$

直接估计出样本的概率密度
贝叶斯估计把 θ 看作 Random variable

递推的贝叶斯估计:



$$p(\theta) \quad p(\theta|x_1) \quad p(\theta|x_1, x_2) \cdots p(\theta|x_1, \dots, x_n)$$

$$p(x|x^{N \rightarrow \infty}) = p(x) \text{ 真实密度函数.}$$

淘宝店铺-酷流科技 掌柜：我是雷锋的朋友

正态分布时的贝叶斯估计

$$x \sim N(\mu, \sigma^2)$$

$\mu \sim N(\mu_0, \sigma_0^2)$ 假设 μ 服从先验分布
根据 X 估计 μ . 用贝叶斯估计化简

$$p(\mu|x) \sim N(\mu_N, \sigma_N^2)$$

$$\mu_N = \frac{N\sigma_0^2}{N\sigma_0^2 + \sigma^2} m_N + \frac{\sigma^2}{N\sigma_0^2 + \sigma^2} \mu_0$$

$$\sigma_N^2 = \frac{\sigma_0^2 \sigma^2}{N\sigma_0^2 + \sigma^2}$$

$$m_N = \frac{1}{N} \sum_i x_i$$

μ_N 由2部分组成 m_N 和 μ_0 (先验知识), 当 $N \rightarrow \infty$

$$\mu_N = m_N$$

当 $N \rightarrow 0$, σ_0^2 很小, 即先验知识确定 $\mu_N = \mu_0$

$x|X \sim N(\mu_N, \sigma^2 + \sigma_N^2)$ 用样本估计的 $P(x)$ 为差变大


淘宝店铺-酷流科技 掌柜：我是雷锋的朋友

概率密度估计的非参数方法.



写不出 $p(x)$ 的形式怎么办?

• 直方图法.



(1) 把样本 x 的每个分量在其取值范围内分成 k 个等间隔的小窗。如果 x 是 d 维向量, 则这种分割就会得到 k^d 个小体积或者称作小舱, 每个小舱的体积记作 V 。

(2) 统计落入每个小舱内的样本数目 q_i 。

(3) 把每个小舱内的概率密度看作是常数, 并用 $q_i/(NV)$ 作为其估计值, 其中 N 为样本总数。

淘宝店铺-酷流科技 掌柜：我是雷锋的朋友

分析非参数估计基本原理:

x 落入 R_1 区域 region-1 的概率

$$p = \int_{R_1} p(x) dx$$

k 个样本落入 R_1 的概率

$$P_k = C_N^k p^k \cdot (1-p)^{N-k}$$

在 R_1 中 k 的期望

$$E(k) = Np, \quad \hat{p} = \frac{k}{N}$$

在 R_1 , k 的众数 (最可能取值)

$$p_m = \max p_k, \quad m = [(N+1)p], \quad [\] \text{ 为取整.}$$

$$\hat{p} = \int_{R_1} p(x) dx = p(x) \cdot V.$$

将 $p(x)$ 在这个小区域看作定值.

$$\hat{p}(x) = \frac{\hat{p}}{V} = \frac{k/N}{V}$$

所以,小舱的选择应该与样本总数相适应。理论上讲,假定样本总数是 n ,小舱的体积为 V_n ,在 x 附近位置上落入小舱的样本个数是 k_n ,那么当样本趋于无穷多时 $\hat{p}(x)$ 收敛于 $p(x)$ 的条件是

$$(1) \lim_{n \rightarrow \infty} V_n = 0, \quad (2) \lim_{n \rightarrow \infty} k_n = \infty, \quad (3) \lim_{n \rightarrow \infty} \frac{k_n}{n} = 0 \quad (3-62)$$

直观的解释是:随着样本数的增加,小舱体积应该尽可能小,同时又必须保证小舱内有充分的样本,但每个小舱内的样本数又必须是总样本数中很小的一部分。

不足: 样本密度大的区域,一个小舱有很多样本, 密度小的区域一个小舱只有很少或没有样本,导致密度估计在样本密度不同的区域不一致。

淘宝店铺-酷流科技 掌柜:我是雷锋的朋友

k_n 近邻估计方法

$$\hat{f}(x) = \frac{k_n/N}{V}$$

在任一点 x , 调整 V 的体积, 直到恰好有 k_n 个样本落入, 兼顾在高密度区域的分辨率和低密度区域连续性.




图 3-4 k_N 法的窗口宽度与样本密度的关系示意

$N = \infty$ 即真实的 $p(x)$ 的 k_N 法估计的效果举例




图 3-5 不同样本数和不同参数下 k_N 法估计的效果举例

淘宝店铺-酷流科技 掌柜：我是雷锋的朋友

Parzen 窗法

$$\text{小窗} V = h^d$$

$$g([u_1, u_2, \dots, u_d]) = \begin{cases} 1, & \text{若 } |u_j| \leq \frac{1}{2} \\ 0, & \text{其他} \end{cases}$$

$$K_N = \sum_{i=1}^N g\left(\frac{x - x_i}{h}\right)$$

将直方图估计的 K_N 替换为了
自适应 K_N

$$\hat{f}(x) = \frac{1}{NV} \sum_{i=1}^N g\left(\frac{x-x_i}{h}\right)$$

以核函数密度

$$K(x, x_i) = \frac{1}{V} g\left(\frac{x-x_i}{h}\right)$$

反应了一个观测样本 x_i 对在 x 处
核函数密度估计的贡献，与
 x_i 到 x 的距离有关

ATTENTION

$$\hat{p}(x) = \frac{1}{N} \sum_{i=1}^N k(x, x_i)$$

$k(x, x_i)$
的条件

$$\int \hat{p}(x) dx = \frac{1}{N} \sum_{i=1}^N \int k(x, x_i) dx = 1$$

$$\sum_{i=1}^N \int k(x, x_i) dx = N$$

$$\int k(x, x_i) dx = 1 \text{ 是满足的}$$

$$k(x, x_i) \geq 0. \text{ 核函数条件}$$

核函数可定义多种.

淘宝店铺-酷流科技 掌柜：我是雷锋的朋友

图 3-6 给出用高斯窗估计一个概率密度函数的例子。




图 3-6 Parzen 窗估计概率密度函数示例

又加了个效果

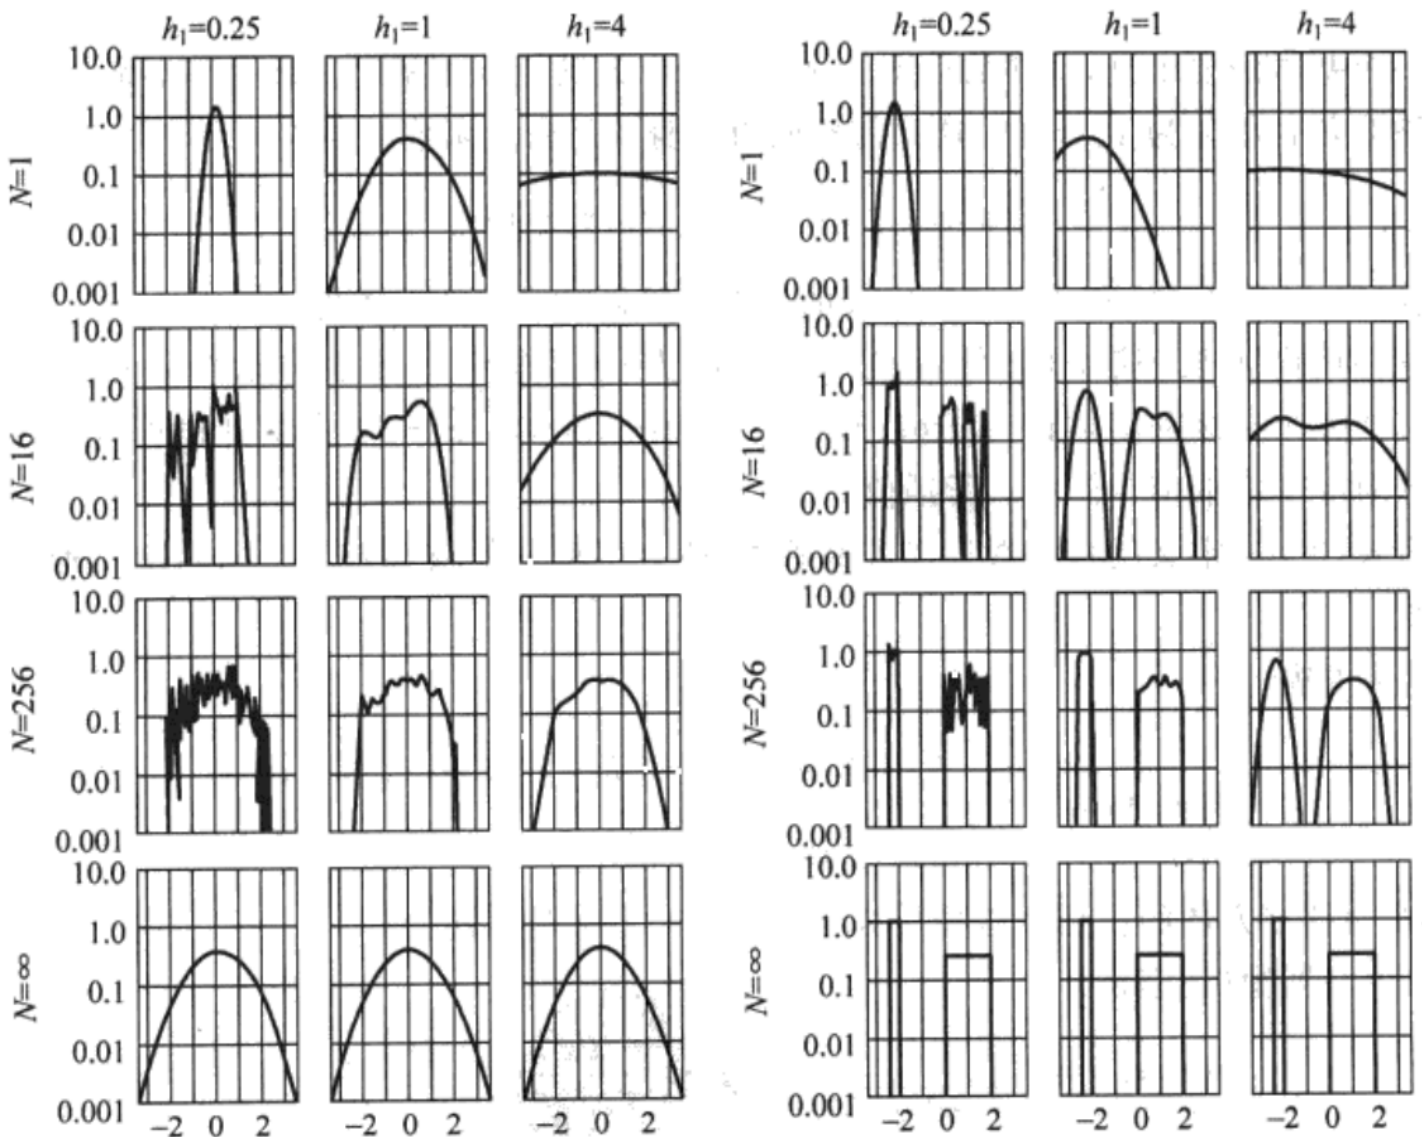


图 3-7 不同样本数和不同参数下 Parzen 窗估计的效果示例

窗口宽度 h 是平滑参数, h 越大越平滑.

Non-parametric 不足

① 对样本数目需求大

② 计算存储量大

优点: 能收敛于任何未知密度.