

# 线性分类器

两步贝叶斯决策：首先根据样本进行概率密度估计，在根据估计的概率密度求分界面。

概率密度函数做决策，最终也是也是依靠判别函数。p29,理解知识点的关联关系。

判别式模型:直接从数据中估计判别函数的参数，而不必估计概率密度函数。

基于样本设计分类器需要三个要素：

- 1.判别函数（分类器）的类型
- 2.分类器设计的目标或准则
- 3.设计算法利用数据搜索到最优的参数（优化）

## 判别函数类、准则、优化算法

### 4.2 判别函数的基本概念

#### TransR

$$x = x_p + r \frac{w}{\|w\|}$$


$$g(x) = w^T x + w_0 = w^T \left( x_p + r \frac{w}{\|w\|} \right) + w_0$$

$$= w^T x_p + w_0 + r \frac{w^T w}{\|w\|}$$

$$= r \frac{w^T w}{\|w\|} = r \frac{\|w\|^2}{\|w\|} = r \|w\|$$

$$r = \frac{g(x)}{\|w\|}$$

$r$ 是 $x$ 到 $H$ 的垂直距离  $x_p$ 是射影向量



超平面的方向由  $w$  确定，它的位置由  $w_0$  确定。

判别函数  $g(x)$  正比于  $x$  点到超平面的代数距离，带正负号，也就是  $r$ ，类似于代数余子式的说法。

## 4.3 Fisher线性判别分析

主要解决两类的线性判别问题，Fisher线性判别的思想是选择投影方向，使投影后两类相隔尽可能远，而同时每一类内部的样本又尽可能聚集。

应该找哪个方向去投影最好呢？

$$y_i = w^T x_i, \quad w \text{ 就是投影方向}$$

$x_i$  样本， $y_i$  是新样本

Fisher判别准则 (要素2)

要素1就是  $y = w^T x + w_0$

$$\max_w J_F(w) = \frac{w^T S_b w}{w^T S_w w}$$

广义 Rayleigh 商.

倒着看书

倒背如流有道理

$S_b$ : 类间散度 between-class

$S_w$ : 类内散度 within-class

$$\max J_F(W) = \frac{\tilde{S}_b}{\tilde{S}_w} = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\tilde{S}_1^2 + \tilde{S}_2^2}$$

$$W^T S_b W = \tilde{S}_b \quad \left\{ \begin{array}{l} \text{why?} \end{array} \right.$$

$$W^T S_w W = \tilde{S}_w$$

倒着看书，  
就会问why

$$\tilde{S}_b = (\tilde{m}_1 - \tilde{m}_2)^2 = (W^T m_1 - W^T m_2)^2$$

$$= W^T (m_1 - m_2)(m_1 - m_2)^T W$$

$$= W^T S_b W$$

$$S_b = (m_1 - m_2)(m_1 - m_2)^T$$

$$m_i = \frac{1}{N_i} \sum_{x_j \in X_i} x_j$$

$$\tilde{S}_w = \tilde{S}_1^2 + \tilde{S}_2^2$$

$$= \sum_{x_j \in X_1} (w^T x_j - w^T m_1)^2 + \sum_{x_j \in X_2} (w^T x_j - w^T m_2)^2$$

$$= \sum_{x_j \in X_1} w^T (x_j - m_1) (x_j - m_1)^T w + \sum_{x_j \in X_2} w^T (x_j - m_2) (x_j - m_2)^T w$$

$$= w^T S_1 w + w^T S_2 w$$

$$= w^T S_w w$$

$$S_w = S_1 + S_2$$

优化：（要素3）

最优投影方向  $w^* = S_w^{-1} (m_1 - m_2)$

$$\max w^T S_b w$$

s.t.  $w^T S_w w = C \neq 0$  subject to 固定分母

Lagrange函数的无约束极值问题，  
优化过程按部就班去做

$$g(x) = W^T x + W_0 \geq 0 \quad \text{则} \quad x \in \begin{cases} W_1 \\ W_2 \end{cases}$$

当样本是正态分布且类协方差矩阵相同，最优贝叶斯分类器如下

$$W = \Sigma^{-1} (\mu_1 - \mu_2)$$

$$W_0 = -\frac{1}{2} (\mu_1 + \mu_2)^T \Sigma^{-1} (\mu_1 - \mu_2) + \ln \frac{p(w_1)}{p(w_2)}$$

因此在这种情况下，Fisher线性判别的方向就是最优贝叶斯方向

$$W_0 = -\frac{1}{2} (m_1 + m_2)^T S_w^{-1} (m_1 - m_2) - \ln \frac{p(w_2)}{p(w_1)}$$

$$W^* = S_w^{-1} (m_1 - m_2) \quad \text{投影方向}$$

$$\tilde{m}_1 = m_1^T \cdot W^* \quad m_1 \text{ 沿 } W^* \text{ 投影}$$

$$W_0 = -\frac{1}{2} (\tilde{m}_1 + \tilde{m}_2) \quad \text{当 } p(w_1) = p(w_2)$$

$$= -\tilde{m}$$

$$\tilde{m} = \frac{\tilde{m}_1 \cdot n_1 + \tilde{m}_2 \cdot n_2}{n_1 + n_2} \quad \text{当 } n_1 = n_2 = \frac{1}{2} \tilde{m}_1 + \frac{1}{2} \tilde{m}_2$$

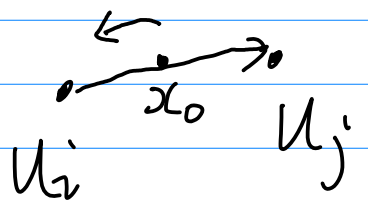
总体平均值是各类平均值的加权组合

先验概率大的要占据更大的决策空间，因此当先验概率不相等，决策面向先验概率小的那边偏

$$(2-80) \cdot (2-88)$$

$x_0$  是决策面上的点.  $W(x_0 - x_0) = 0$  成立

$$x_0 = \frac{1}{2}(M_i + M_j) - k \cdot \ln \frac{P(w_i)}{P(w_j)} (M_i - M_j)$$


 $\neq \frac{P(w_i)}{P(w_j)}$

则  $\vec{x}_0' = \vec{x}_0 - (M_i - M_j)$

$$k \cdot \ln \frac{P(w_i)}{P(w_j)} > 0$$

(4-2)  $\vec{W}$  指向  $R_1$  为正则

若  $\ln \frac{P(w_2)}{P(w_1)} > 0$  则  $W^T \cdot x > 0$  才行 故  $x$  落入正则更深才行



## 4.4感知器