

二次判别函数

$$\begin{aligned} g(x) &= \mathbf{x}^T \mathbf{W} \mathbf{x} + \mathbf{w}^T \mathbf{x} + w_0 \\ &= \sum_{k=1}^d w_{kk} x_k^2 + 2 \sum_{j=1}^{d-1} \sum_{k=j+1}^d w_{jk} x_j x_k + \sum_{j=1}^d w_j x_j + w_0 \end{aligned}$$

其中, \mathbf{W} 是 $d \times d$ 维实对称矩阵, \mathbf{w} 为 d 维向量。

不难看出,这个判别函数中包含 $0.5d(d+3)+1$ 个参数,因此如果像线性判别函数那样,直接根据一定的规则从数据去学习这些参数,计算起来会非常复杂,而且在样本数不足够多时估计如此多的参数,结果的可靠性和推广能力很难保证。

为什么有这些参数？

因为实对称矩阵参数的个数是, $0.5d(1+d)$, \mathbf{w} 有 d 个参数, 最后有 1 个 w_0 , 总计 $0.5d(d+3)+1$

实际中,人们在应用二次判别函数时,往往采用参数化的方法来估计二次判别函数,知道形式,不知道参数。比如,人们往往假定每一类数据都是正态分布,每一类的判别函数如下

$$g_i(\mathbf{x}) = K_i^2 - (\mathbf{x} - \mathbf{m}_i)^T \boldsymbol{\Sigma}_i^{-1} (\mathbf{x} - \mathbf{m}_i)$$

K_i^2 是一个阈值项,它受协方差矩阵和先验概率的影响。判别函数就是样本到均值的 Mahalanobis 距离的平方与固定阈值的比较,样本的均值和方差可以用下面的估计

$$\hat{m}_i = \frac{1}{N_i} \sum_{j=1}^{N_i} x_j$$

$$\hat{\Sigma}_i = \frac{1}{N_i - 1} \sum_{j=1}^{N_i} (x_j - \hat{m}_i) (x_j - \hat{m}_i)^T$$

1. 当两类都近似正态分布时，两类样本的分布各自比较集中，决策面方程为

$$\text{若 } g_1(x) - g_2(x) \geq 0, \text{ 则 } x \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$

2. 两类中 ω_1 一类分布比较成团(近似正态分布),另一类 ω_2 则比较均匀地分布在第一类附近,这种情况下只要对第一类求解其二次判别函数即可,即

$$g(x) = K^2 - (x - \hat{m}_1)^T \hat{\Sigma}_1^{-1} (x - \hat{m}_1)$$

$$\text{若 } g(x) \geq 0, \text{ 则 } x \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$

同样,可以用 K^2 来调整决策的偏向。直观解释是,当样本到 ω_1 类均值的 Mahalanobis 距离的平方小于 K^2 时则决策为 ω_1 类,否则决策为 ω_2 类。

淘宝店铺-酷流科技 掌柜：我是雷锋的朋友