

式(或为了实现方便的考虑将判别函数设定为某种较简单的形式),再通过训练样本确定其中的参数,就能够更简便地设计出分类器。这就是从样本出发直接设计分类器的思路,本书第4章、第5章中的方法及第15章中介绍的支持向量机等都属于这类方法。在很多实际问题中,这类方法往往更具实用价值。

这里提到的方法都是分两步来解决模式识别问题的,即首先根据已知数据(训练样本)设计分类器,然后用它对未知数据进行分类。能否直接从训练样本出发把未知数据分类呢?本书第6章将要介绍的近邻法就是采用了这种做法。

## 习 题

2.1 如果只知道各类的先验概率,最小错误率贝叶斯决策规则应如何表示?

2.2 利用概率论中的乘法定理和全概率公式证明贝叶斯公式

$$P(\omega_i | \mathbf{x}) = \frac{p(\mathbf{x} | \omega_i)P(\omega_i)}{p(\mathbf{x})}$$

2.3 证明:在两类情况下  $P(\omega_1 | \mathbf{x}) + P(\omega_2 | \mathbf{x}) = 1$ 。

2.4 分别写出在以下两种情况

(1)  $P(\mathbf{x} | \omega_1) = P(\mathbf{x} | \omega_2)$

(2)  $P(\omega_1) = P(\omega_2)$

下的最小错误率贝叶斯决策规则。

2.5 (1)对  $c$  类情况推广最小错误率贝叶斯决策规则;

(2)指出此时使错误率最小等价于后验概率最大,即

$$P(\omega_i | \mathbf{x}) > P(\omega_j | \mathbf{x}) \quad \text{对一切 } j \neq i \text{ 成立时, } \mathbf{x} \in \omega_i。$$

2.6 对两类问题,证明最小风险贝叶斯决策规则可表示为

$$\text{若 } \frac{p(\mathbf{x} | \omega_1)}{p(\mathbf{x} | \omega_2)} \geq \frac{(\lambda_{12} - \lambda_{22})P(\omega_2)}{(\lambda_{21} - \lambda_{11})P(\omega_1)}, \text{ 则 } \mathbf{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}。$$

2.7 若  $\lambda_{11} = \lambda_{22} = 0, \lambda_{12} = \lambda_{21}$ , 证明此时最小最大决策面使来自两类的错误率相等。

2.8 对于同一个决策规则判别函数可定义成不同形式,从而有不同的决策面方程,指出决策区域是不变的。

2.9 写出两类和多类情况下最小风险贝叶斯决策判别函数和决策面方程。

2.10 随机变量  $l(\mathbf{x})$  定义为

$$l(\mathbf{x}) = \frac{p(\mathbf{x} | \omega_1)}{p(\mathbf{x} | \omega_2)}, l(\mathbf{x}) \text{ 又称为似然比, 试证明}$$

(1)  $E\{l^n(\mathbf{x}) | \omega_1\} = E\{l^{n-1}(\mathbf{x}) | \omega_2\}$

(2)  $E\{l(\mathbf{x}) | \omega_2\} = 1$

(3)  $E\{l(\mathbf{x}) | \omega_1\} - E\{l(\mathbf{x}) | \omega_2\} = \text{Var}\{l(\mathbf{x}) | \omega_2\}$

2.11  $x_j (j=1, 2, \dots, n)$  为  $n$  个独立随机变量, 有

$$E[x_j | \omega_i] = i j \eta \quad \text{Var}[x_j | \omega_i] = i^2 j^2 \sigma^2$$

计算在  $\lambda_{11} = \lambda_{22} = 0$  及  $\lambda_{12} = \lambda_{21} = 1$  情况下, 由贝叶斯决策引起的错误率。(提示: 用中心极限定理)

2.12 写出离散情况的贝叶斯公式。

2.13 把连续情况的最小错误率贝叶斯决策推广到离散情况,并写出其判别函数。

2.14 写出离散情况条件风险  $R(a_i|\mathbf{x})$  的定义,并指出其决策规则。

2.15 证明多元正态分布的等密度点轨迹是一个超椭球面,且其主轴方向由  $\Sigma$  的特征向量决定,轴长度由  $\Sigma$  的特征值决定。

2.16 证明 Mahalanobis 距离  $r$  符合距离定义三公理,即

(1)  $r(a,b)=r(b,a)$

(2) 当且仅当  $a=b$  时,  $r(a,b)=0$

(3)  $r(a,c) \leq r(a,b) + r(b,c)$

2.17 若将  $\Sigma^{-1}$  阵写为

$$\Sigma^{-1} = \begin{bmatrix} h_{11} & h_{12} & \cdots & h_{1d} \\ h_{12} & h_{22} & \cdots & h_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ h_{1d} & h_{2d} & \cdots & h_{dd} \end{bmatrix}$$

证明 Mahalanobis 距离平方为

$$Y^2 = \sum_{i=1}^d \sum_{j=1}^d h_{ij} (x_i - \mu_i)(x_j - \mu_j)$$

2.18 分别对于  $d=2, d=3$  证明对应于 Mahalanobis 距离  $Y$  的超椭球体积是

$$V = V_d |\Sigma|^{-\frac{1}{2}} Y^d$$

其中  $V_d$  是  $d$  维单位超球体积

$$V_d = \begin{cases} \pi^{d/2} \left/ \left( \frac{d}{2} \right) ! \right. & d=2 \\ \frac{2^d \pi^{(d-1)/2} \left( \frac{d-1}{2} \right) !}{d!} & d=3 \end{cases}$$

2.19 假定  $x$  和  $m$  是两个随机变量,并设在给定  $m$  时,  $x$  的条件密度为

$$p(x|m) = (2\pi)^{-\frac{1}{2}} \sigma^{-1} \exp \left\{ -\frac{1}{2} (x-m)^2 / \sigma^2 \right\}$$

再假定  $m$  的边缘分布是正态的,期望值为  $m_0$ ,方差为  $\sigma_m^2$ ,证明

$$p(m|x) = \frac{(\sigma^2 + \sigma_m^2)^{-\frac{1}{2}}}{(2\pi)^{-\frac{1}{2}} \sigma \sigma_m} \exp \left[ -\frac{1}{2} \frac{\sigma^2 + \sigma_m^2}{\sigma^2 \sigma_m^2} \left( m - \frac{\sigma_m^2 x + m_0 \sigma^2}{\sigma^2 + \sigma_m^2} \right)^2 \right]$$

(提示:利用贝叶斯公式)

2.20 对  $\Sigma_i = \sigma^2 I$  的特殊情况,证明

(1) 若  $P(\omega_i) \neq P(\omega_j)$ , 则超平面靠近先验概率较小的类;

(2) 在什么情况下,先验概率对超平面的位置影响不大。

2.21 对  $\Sigma_i = \Sigma$  的特殊情况,指出在先验概率不等时,决策面沿  $\mu_i$  点与  $\mu_j$  点连线向先验概率小的方向移动。

2.22 似然比决策准则为

$$\text{若 } l(\mathbf{x}) = \frac{p(\mathbf{x}|\omega_1)}{p(\mathbf{x}|\omega_2)} \geq \frac{P(\omega_2)}{P(\omega_1)} \quad \text{则 } \mathbf{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}.$$

负对数似然比为  $h(\mathbf{x}) = -\ln[l(\mathbf{x})]$ , 当  $p(\mathbf{x}|\omega_i)$  是均值向量为  $\mu_i$  和协方差矩阵为  $\Sigma_i$  的正态分布时:

- (1) 试推导出  $h(\mathbf{x})$ , 并指出其决策规则;
- (2) 当  $\Sigma_1 = \Sigma_2 = \Sigma$  时, 推导  $h(\mathbf{x})$  及其决策规则;
- (3) 分析(1), (2)两种情况下的决策面类型。

**2.23** 二维正态分布,  $\mu_1 = (-1, 0)^T, \mu_2 = (1, 0)^T, \Sigma_1 = \Sigma_2 = I, P(\omega_1) = P(\omega_2)$ 。

试写出负对数似然比决策规则。

**2.24** 习题 2.23 中, 若  $\Sigma_1 \neq \Sigma_2$ ,

$$\Sigma_1 = \begin{bmatrix} 1 & \frac{1}{2} \\ \frac{1}{2} & 1 \end{bmatrix}, \quad \Sigma_2 = \begin{bmatrix} 1 & -\frac{1}{2} \\ -\frac{1}{2} & 1 \end{bmatrix},$$

写出负对数似然比决策规则。

**2.25** 在习题 2.24 的情况下, 若考虑损失函数  $\lambda_{11} = \lambda_{22} = 0, \lambda_{12} = \lambda_{21}$ , 画出似然比阈值与错误率间的关系。

- (1) 求出  $P(e) = 0.05$  时完成 Neyman-Pearson 决策时总的错误率;
- (2) 求出最小最大决策的域值和总的错误率。