

4.8 讨论

线性判别函数是形式最简单的判别函数,但因为它具有计算简单、在一定条件下能够实现最优分类的性质,因此在实际中得到了广泛的应用。很多情况下,虽然所研究的问题并不是线性可分的,但因为受到维数高、样本数有限等实际情况的限制,仍经常使用线性分类器。这不但是在容许一定的错误率时的一种“有限合理性”的选择,而且实际上,在这些条件下,即使采用更复杂的分类器设计方法也往往并不能得到更好的结果,有时甚至结果更差。

在后面两章我们将要看到,在线性分类器基础上,用分段线性分类器可以实现更复杂的分类面。而本章介绍的感知器准则下的线性分类器,实际上就是人工神经网络中最典型的多层感知器的原型(参见第 11 章)。在“4.1.2 小节”中提出的广义线性判别函数,虽然在这里因为维数灾难问题没有得到进一步推广,但在第 13 章将看到,在统计学习理论中从全新的角度对广义线性分类器进行了研究,巧妙地克服了维数灾难问题,进而发展出了最新的模式识别方法——支持向量机,成为解决有限样本情况下非线性分类问题的有效手段。

习 题

4.1 (1) 指出从 x 到超平面 $g(x) = w^T x + w_0 = 0$ 的距离

$$r = \frac{|g(x)|}{\|w\|}$$

是在 $g(x_0) = 0$ 的约束条件下,使 $\|x - x_0\|^2$ 达到极小的解;

(2) 指出在超平面上的投影是

$$x_p = x - \frac{g(x)}{\|w\|^2} w$$

4.2 设有一维空间二次判别函数

$$g(x) = 5 + 7x + 9x^2$$

(1) 试映射成广义齐次线性判别函数;

(2) 总结把高次函数映射成齐次线性函数的方法。

4.3 (1) 通过映射,把一维二次判别函数

$$g(x) = a_1 + a_2 x + a_3 x^2$$

映射成三维广义齐次线性判别函数;

(2) 若 x 在一维空间具有分布密度 $p(x)$,说明三维空间中的分布密度退化成只在一条曲线上有值,且曲线上值无穷大。

4.4 对于二维线性判别函数

$$g(x) = x_1 + 2x_2 - 2$$

(1) 将判别函数写成 $g(x) = w^T x + w_0$ 的形式,并画出 $g(x) = 0$ 的几何图形;

(2) 映射成广义齐次线性判别函数

$$g(x) = a^T y$$

(3) 指出上述 X 空间实际是 Y 空间的一个子空间, 且 $\mathbf{a}^T \mathbf{y} = 0$ 对 X 子空间的划分与原空间中 $\mathbf{w}^T \mathbf{x} + w_0 = 0$ 对原 X 空间的划分相同, 并在图上表示出来。

4.5 指出在 Fisher 线性判别中, \mathbf{w} 的比例因子对 Fisher 判别结果无影响的原因。

4.6 证明两向量外积组成的矩阵一般是奇异的。

4.7 已知 Fisher 准则函数为

$$J(\mathbf{w}) = \frac{\mathbf{w}^T S_B \mathbf{w}}{\mathbf{w}^T S_W \mathbf{w}}$$

(1) 说明是否一般的分数函数都可以用 Lagrange 乘子法求极值解;

(2) 分析 $J(\mathbf{w})$ 可用 Lagrange 乘子法求解的条件。

4.8 证明在正态等协差条件下, Fisher 线性判别等价于贝叶斯判别。

4.9 证明

(1) 引入余量 b 以后的解区 ($\mathbf{a}^T \mathbf{y}_i \geq b$) 位于原来的解区 ($\mathbf{a}^T \mathbf{y}_i > 0$) 之中;

(2) 与原解区边界之间的距离为 $b / \|\mathbf{y}_i\|$ 。

4.10 证明, 在几何上, 感知准则函数正比于被错分类样本到决策面的距离之和。

4.11 分析在可变增量法中, 余量 b 如何选择较为合理。

4.12 写出 Widrow-Hoff 法程序框图。

4.13 (1) 证明矩阵恒等式

$$(\mathbf{A} + \mathbf{x}\mathbf{x}^T)^{-1} = \mathbf{A}^{-1} - \frac{\mathbf{A}^{-1}\mathbf{x}\mathbf{x}^T\mathbf{A}^{-1}}{1 + \mathbf{x}^T\mathbf{A}^{-1}\mathbf{x}}$$

(2) 利用上式结果证明式(4-98)。

4.14 考虑准则函数

$$J(\mathbf{a}) = \sum_{\mathbf{y} \in \mathcal{S}(\mathbf{a})} (\mathbf{a}^T \mathbf{y} - b)^2$$

其中 $\mathcal{S}(\mathbf{a})$ 是使 $\mathbf{a}^T \mathbf{y} \leq b$ 的样本集合。设 \mathbf{y}_1 是 $\mathcal{S}(\mathbf{a}_k)$ 中的唯一样本, 则 $J(\mathbf{a})$ 的梯度为 $\nabla J(\mathbf{a}_k) = 2(\mathbf{a}_k^T \mathbf{y}_1 - b)\mathbf{y}_1$, 二阶偏导数矩阵为 $D = 2\mathbf{y}_1\mathbf{y}_1^T$ 。

据此证明, 若最优步长选择为

$$\rho_k = \frac{\|\nabla J(\mathbf{a})\|^2}{\nabla J^T(\mathbf{a})D\nabla J(\mathbf{a})}$$

时, 梯度下降法的迭代公式为

$$\mathbf{a}_{k+1} = \mathbf{a}_k + \frac{b - \mathbf{a}_k^T \mathbf{y}_1}{\|\mathbf{y}_1\|^2} \mathbf{y}_1$$

4.15 证明: 当取

$$b = \underbrace{\left[\frac{N}{N_1}, \dots, \frac{N}{N_1}, \frac{N}{N_2}, \dots, \frac{N}{N_2} \right]^T}_{N_1 \uparrow \quad N_2 \uparrow}$$

时, MSE 解等价于 Fisher 解。

4.16 证明:

(1) 式(4-113)表示的向量 $\mathbf{y} - \frac{\mathbf{a}^T \mathbf{y}}{\|\mathbf{w}\|^2} \begin{bmatrix} 0 \\ \mathbf{w} \end{bmatrix}$ 表示 \mathbf{y} 到 X 空间中超平面上的投影。

(2) 该投影正交于 X 空间的超平面。

4.17 在多类问题中,如果一组样本可被一线性机器全部正确分类,则称这组样本是线性可分的。对任意 ω_i 类,如果能用一个超平面把标以 ω_i 类的样本同所有其他样本分开,则称这组样本为总体线性可分的。举例说明,总体线性可分必定线性可分,但反之不然。

4.18 设有一组样本。若存在 $c(c-1)/2$ 个超平面 H_{ij} ,使 H_{ij} 能把属于 ω_i 类的样本同属于 ω_j 类的样本分开,则称这组样本是成对线性可分的。举例说明,成对线性可分的样本不一定是线性可分的。